课程作业 · AI 辅助设计“梯度类”方法并实验验证 · RSI Harness 工程

门控全信息策略梯度（GFPG）

面向 LLM Harness 受限自我改进的梯度类方法：设计、推导与真实 API 实验验证

Gated Full-information Policy Gradient for Budget-aware Self-Improvement of an LLM Harness

固定基础模型与提示词，只用 CPU 训练一个 48 参数的 softmax 路由器：为每道数学题在 direct（只给答案）、reason（简短分步）、review（分步后复核）之间选择执行路线，以“正确率 − token 成本”为目标做精确梯度上升，并通过验证门控完成可审计的增量自我改进。本报告给出方法推导、AI 辅助设计过程，以及在 GSM8K 上用 938 次真实 API 请求得到的完整正负结果。

48	1.6×10^{-10}	−1.87%	0.9565
可训练参数 纯 CPU 毫秒级更新	解析梯度与有限差分 的最大绝对误差	测试集 token（相对初始） 区间不含 0 · 准确率不变	最佳固定策略效用 高于学习路由器 0.9448

作业要求	针对梯度类方法，AI 辅助下设计一个新的“梯度类”方法，并通过实验验证其有效性；可以是一个 RSI 相关的 Harness 工程。
方法	全信息精确策略梯度 + 预算感知效用 + 验证门控增量自改进 + 测试前冻结协议（第 3 节）
实验	GSM8K 官方 train/test 抽样，训练 / 验证 / 测试 = 128 / 48 / 128 题；模型 `deepseek-v4.1-flash`，温度 0
可复现性	离线复核脚本无需密钥即可重算全部指标；所有图表与数值由脚本从实验产物生成
项目仓库	https://github.com/10255102560/Best1
日期	2026 年 11 月

说明：本报告中的实验数值全部由 `scripts/make_figures.py` 从 `artifacts/gsm8k_flash_v1/` 自动生成；负面结果（未超过最佳固定策略）按预先写定的解释规则如实报告。

摘　要

本文围绕课程主题“梯度类方法”，在 AI 编程助手辅助下设计并实现了一种面向 LLM Harness（大模型外层执行框架）受限自我改进的梯度类方法，称为**门控全信息策略梯度**（Gated Full-information Policy Gradient，GFPG）。实验固定基础模型与提示词，只训练一个 48 参数的线性 softmax 路由器，为每道数学题在 direct、reason、review 三条执行路线中选择其一，最大化“正确率 − 0.05×token/1000”的成本感知效用。与依赖动作采样的 REINFORCE 类方法、以及把自然语言反馈称作“梯度”的 TextGrad 不同，GFPG 先为每道训练题*实际测量全部动作*的结果，构成完整奖励矩阵，从而得到期望效用（含熵与 L_2 正则）的**解析梯度**；再以“新批次反馈 → 暖启动梯度上升 → 验证门控 → 接纳或回退”的四轮循环实现自我改进，并在任何测试请求之前冻结版本。

在 GSM8K 官方数据的 128/48/128 划分上，我们用 `deepseek-v4.1-flash` 发起 938 次真实 API 请求（上限 980）。结果表明：(1) 解析梯度与中心差分的最大误差为 1.6×10^{-10}；每题只采样一个动作时（约 164 次调用），REINFORCE 估计与精确梯度方向的平均余弦相似度仅约 0.25。(2) 冻结路由器在独立测试集上与初始流程同样答对 123/128 题，平均 token 减少 6.14（−1.87%），逐题配对 bootstrap 95% 区间为 $[-11.47, -1.83]$，不含 0。(3) 但验证集选出的固定 direct 策略答对 124/128、token 减少 −25.28%，学习路由器的效用显著低于这一强基线；oracle 诊断显示三条路线在该基准上几乎没有可供路由利用的互补空间（仅 1.36%）。我们据此分析了“决策不可见的更新”、步长预算不足与训练集稀有翻转题等原因，并给出改进方向。

关键词：梯度类方法；策略梯度；全信息反馈；LLM Harness；递归自我改进（RSI）；成本感知路由；配对 bootstrap

目 录

1 引言 **1**
1.1 背景：Harness 层的自我改进 . . . 1
1.2 作业要求与本项目的对应 . . . 1
1.3 主要贡献 . . . 1

2 问题建模 **2**
2.1 固定模型下的三条执行路线 . . . 2
2.2 成本感知效用 . . . 2
2.3 为什么用梯度类方法 . . . 2

3 方法：门控全信息策略梯度（GFPG） **2**
3.1 特征与线性 softmax 路由器 . . . 2
3.2 优化目标 . . . 3
3.3 解析梯度推导 . . . 3
3.4 与已有“梯度”方法的比较 . . . 4
3.5 增量自我改进循环与验证门控 . . . 4
3.6 工程实现要点 . . . 4

4 AI 辅助设计过程 **5**
4.1 人机分工 . . . 6
4.2 关键设计迭代 . . . 6
4.3 如何核查 AI 的产出 . . . 6

5 实验设置 **7**

6 实验结果 **7**
6.1 方法正确性验证 . . . 7
6.2 独立测试集主结果 . . . 8
6.3 配对统计检验 . . . 9
6.4 自我改进过程 . . . 10
6.5 成本与预算 . . . 11

7 分析与讨论 **12**
7.1 GFPG 在哪些方面是有效的 . . . 12
7.2 为什么没有超过最佳固定策略 . . . 12
7.3 复核为何无效 . . . 12
7.4 对 RSI Harness 工程的启示 . . . 13

8 局限性与后续工作 **13**

9 结论 **13**

附录 A 复现指南 **14**

附录 B 仓库结构 **15**

附录 C 自动化测试清单 **15**

1 引言

1.1 背景：Harness 层的自我改进

大模型应用的效果不仅取决于模型权重，也取决于外层的 harness：提示词怎么写、调用几次、是否让模型自我复核、何时停止。近年来出现了一批“让系统自己改进自己”的工作：TextGrad 用 LLM 生成的自然语言反馈充当“文本梯度”[6]；ADAS 由元智能体编写新的代理代码 [7]；GEPA 通过轨迹反思进化提示词 [8]；Darwin Gödel Machine 修改自身代码并用基准验证 [9]。这些方法表达力很强，但其中的“梯度”往往不是严格意义上的数值导数，改进过程也难以用最优化课程中的工具——目标函数、梯度、步长、收敛性——来分析和验证。

本项目选择相反的路线：**把 harness 的自我改进限制在一个可微、可推导、可验证的参数空间里**，让经典梯度类方法在真实的 LLM 系统上落地，并用严格的实验协议检验它是否真的带来收益。这是一种受限的递归自我改进（RSI）：系统根据自身的运行反馈修改自己的决策参数，但不修改基础模型，也不自动编写新代码。

1.2 作业要求与本项目的对应

表 1 作业要求逐项对应

作业要求	本项目的对应内容	位置
针对梯度类方法	以期望效用为目标的 softmax 策略梯度上升；给出含熵正则的解析梯度，并用有限差分逐分量验证	§3、§6.1
设计“新的”梯度类方法	GFPG：全信息精确梯度 + 预算感知效用 + 验证门控增量自改进 + 测试前冻结协议	§3
AI 辅助下设计	AI 编程助手参与问题筛选、梯度推导、实现、测试与报告；人负责目标、约束与审核	§4
通过实验验证有效性	938 次真实 API 请求；独立测试集；配对 bootstrap；强基线与 oracle 诊断；正负结果均报告	§5–§7
RSI 相关的 Harness 工程	四轮“反馈 → 梯度更新 → 门控 → 接纳 / 回退”循环；预算账本、缓存、冻结与离线复核	§3.5、§3.6

1.3 主要贡献

1. **方法**：提出 GFPG。利用“每条动作都实际测量”的全信息反馈，把采样式策略梯度变为期望效用的精确梯度，并把它嵌入带累计准确率守卫的验证门控循环，构成可审计的 harness 自我改进（§3）。
2. **工程**：实现可复现的 harness：持久化预算账本（失败重试也计入上限）、防重复计费缓存、review 复用初稿的采集、测试前冻结、无需密钥的离线复核，以及 36 项自动化测试（§3.6）。
3. **实验**：在真实 API 上完成训练、门控与一次性独立测试，以配对 bootstrap 报告相对初始流程与相对最佳固定策略的差异（§6）。
4. **诊断**：如实揭示学习路由器未超过最佳固定策略，并用 oracle 上界、决策变化数与训练集翻转题解释原因，给出可操作的改进方向（§7）。

2　问题建模

2.1　固定模型下的三条执行路线

基础模型、提示词和三条路线都是冻结的，可优化的只是“对哪道题走哪条路线”。三条路线如表 2。

表 2　Harness 的三条执行路线（部署成本按实际调用次数计）

动作	行为	部署调用数
direct	请求只给出最终数值答案 `<answer>number</answer>`	1
reason	请求简洁的分步计算，最后给出答案	1
review	先按 reason 生成初稿，再用第二次请求检查理解、算术与所求量，必要时修正	2

direct 只约束可见输出，不代表模型内部完全没有推理（推理 token 仍可能产生）。答案只接受显式标记的数值，严格数值相等才算正确，不使用 LLM 裁判。

2.2　成本感知效用

对任务 i 与动作 a，记 $c_{ia} \in \{0,1\}$ 为是否答对，T_{ia} 为该路线 API 报告的总 token（review 计两步之和）。定义奖励

$$r_{ia} = c_{ia} - \kappa \frac{T_{ia}}{1000}, \qquad \kappa = 0.05. \tag{1}$$

其含义是：平均每题多花 1000 token，需要换来超过 5 个百分点的准确率提升才“划算”。该权衡在实验前固定；准确率与 token 始终分开报告，避免单一分数掩盖质量下降。token 是计算开销的代理指标，不等同于货币价格。

2.3　为什么用梯度类方法

路由决策依赖题目特征，规则空间是连续的；用 softmax 把“选哪条路线”变成关于参数的光滑概率后，期望效用对参数可微，于是可以用梯度上升在 CPU 上毫秒级地优化，而无需穷举规则或再调用模型。关键问题在于：*梯度从哪里来、是否准确、更新是否安全*。GFPG 的设计正是对这三个问题的回答。

3　方法：门控全信息策略梯度（GFPG）

3.1　特征与线性 softmax 路由器

路由器只读取题面，提取 15 个固定特征：字符数、词数、数字个数、最大数值、句子数的对数尺度，问号数，加 / 减 / 乘 / 除、百分数、顺序、金额、比较类关键词计数，以及小数个数。特征不读取答案、任务 ID 或任何路线输出。设训练集标准化后的特征为 $x_i \in \mathbb{R}^{15}$，参数 $W \in \mathbb{R}^{15\times 3}$、$b \in \mathbb{R}^3$：

$$z_i = W^\top x_i + b, \qquad \pi_\theta(a \mid x_i) = \frac{\exp z_{ia}}{\sum_{k=1}^{3} \exp z_{ik}}, \tag{2}$$

共 $15 \times 3 + 3 = 48$ 个参数。部署与验证一律使用确定性的 $a_i = \arg\max_a \pi_\theta(a \mid x_i)$。

3.2 优化目标

在已观测的完整奖励矩阵 $R = (r_{ia}) \in \mathbb{R}^{N\times 3}$ 上，最大化带熵正则与 L_2 正则的期望效用：

$$J(W,b) = \frac{1}{N}\sum_{i=1}^{N}\Big[\underbrace{\sum_a \pi_{ia}\, r_{ia}}_{\bar r_i\text{：期望效用}} + \tau\, H(\pi_i)\Big] - \frac{\lambda}{2}\|W\|_F^2, \qquad H(\pi_i) = -\sum_a \pi_{ia}\log\pi_{ia}, \tag{3}$$

其中 $\tau = 0.01$、$\lambda = 0.03$，偏置不加正则。熵项防止策略过早塌缩到单一动作，L_2 项抑制小样本过拟合。

3.3 解析梯度推导

softmax 的雅可比为 $\partial\pi_{ia}/\partial z_{ib} = \pi_{ia}(\delta_{ab} - \pi_{ib})$。对期望效用项：

$$\frac{\partial \bar r_i}{\partial z_{ib}} = \sum_a r_{ia}\,\pi_{ia}(\delta_{ab} - \pi_{ib}) = \pi_{ib}\,(r_{ib} - \bar r_i).$$

对熵项，利用 $\sum_a \partial\pi_{ia}/\partial z_{ib} = 0$：

$$\frac{\partial H_i}{\partial z_{ib}} = -\sum_a (\log\pi_{ia} + 1)\,\pi_{ia}(\delta_{ab} - \pi_{ib}) = -\pi_{ib}\big(\log\pi_{ib} + H_i\big).$$

合并得到每道题对 logit 的梯度，再由链式法则得到参数梯度：

GFPG 的精确梯度

$$g_{ib} = \pi_{ib}\Big[r_{ib} - \bar r_i - \tau\big(\log\pi_{ib} + H(\pi_i)\big)\Big], \qquad \nabla_W J = \frac{1}{N}\sum_{i=1}^{N} x_i\, g_i^{\top} - \lambda W, \qquad \nabla_b J = \frac{1}{N}\sum_{i=1}^{N} g_i. \tag{4}$$

更新规则为全批量梯度上升 $\theta \leftarrow \theta + \eta\,\nabla_\theta J(\theta)$，$\eta = 0.2$，每轮 400 步。

精确性。 由于 R 的每个元素都是实际观测值，式 (4) 是目标 (3) 的*精确*梯度，没有蒙特卡洛方差。对比 REINFORCE[1, 2]：它对每题只采样动作 $a_i \sim \pi_i$，用 $\hat g = \frac{1}{N}\sum_i x_i\,(e_{a_i} - \pi_i)(r_{ia_i} - \beta)$ 作无偏估计，方差随采样数下降。“精确”仅指给定已观测奖励矩阵时的梯度计算，并不意味着已知模型对每道题的真实成功概率。

收敛性与部署的关系。 奖励有界、softmax 光滑，J 的梯度 Lipschitz 连续，步长足够小时梯度上升单调提升 J 并收敛到驻点 [4]；但 J 一般非凹，不保证全局最优，softmax 策略梯度在接近确定性策略时还可能进入平台期 [3]。更重要的是，平滑目标 J 的提升*不必*改变 $\arg\max$ 部署决策。因此 GFPG 不以 J 的提升作为改进证据，而是由验证门控直接评估 $\arg\max$ 路由的真实指标。

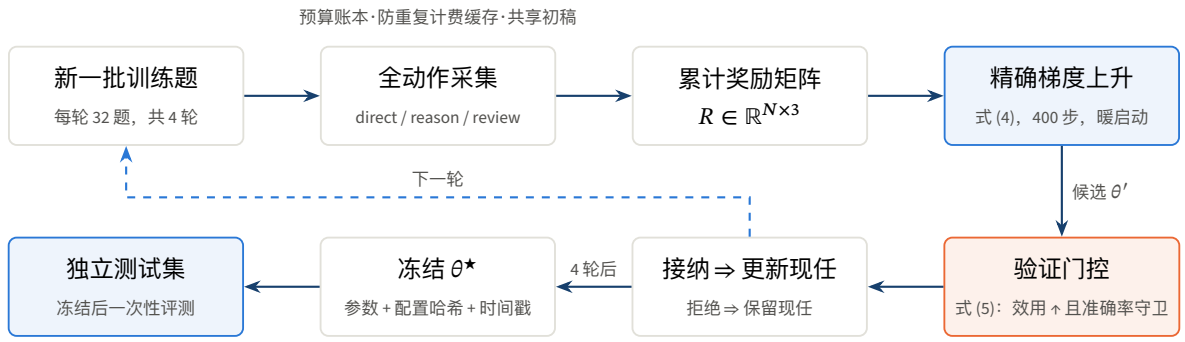


图 1　GFPG 的增量自我改进流程。只有通过门控的候选才会成为现任；四轮结束后先写入冻结文件，之后才首次请求测试集。

3.4 与已有“梯度”方法的比较

表 3　三类“梯度”在 harness 优化中的比较

	REINFORCE / GRPO 类 [1, 10]	TextGrad[6]	GFPG（本文）
反馈形式	采样动作的标量奖励	LLM 生成的自然语言批评	每题全部动作的实测奖励
“梯度”性质	数值梯度的无偏估计，有采样方差	非数值导数，不可做有限差分验证	期望效用的解析梯度，零采样方差
可优化对象	模型权重或策略参数	提示词等文本变量	48 个路由参数
每题数据成本	每个采样 1–2 次调用	多次 LLM 调用	固定 3 次（review 复用初稿）
可验证性	统计意义	依赖人工判断	逐分量有限差分（图 2a）

GFPG 的组成部分（softmax 策略梯度、熵正则、验证集早停）都是经典方法；本项目的设计在于把它们针对 LLM harness 的特点组合起来：动作少（3 条）且可共享初稿，使全信息采集的成本可控；而全信息又把随机梯度变成确定性梯度，让最优化课程中的分析工具可以直接使用。

3.5 增量自我改进循环与验证门控

初始 harness 总是走 reason（$W = 0$，$b = (0, 0.5, 0)$）。训练题分 4 批、每批 32 题到达，每轮执行算法 1，流程见图 1。接纳规则要求验证效用严格提升，同时准确率不低于“初始与现任中的较高者”减去 0.03：

$$U_{\text{val}}(\theta') > U_{\text{val}}(\theta_{\text{inc}}) + 10^{-6} \quad \text{且} \quad \text{Acc}_{\text{val}}(\theta') \geq \max\{\text{Acc}_{\text{val}}(\theta_0),\, \text{Acc}_{\text{val}}(\theta_{\text{inc}})\} - 0.03. \tag{5}$$

取“较高者”是为了防止每轮各下降 3 个百分点而累积退化。门控是自我修改的安全阀：候选不合格时系统保留现任版本，被拒候选仍存档以供审计。

3.6 工程实现要点

- **预算账本**：每次 HTTP 调用之前先写入并 `fsync` 一条 attempt 记录；失败重试同样计入上限；进程重启从账本恢复计数，不会重置预算。
- **防重复计费缓存**：缓存键为“接口地址 + 模型 + 消息 + 参数”的 SHA-256；同一请求并发时只发一次；缓存文件损坏时拒绝自动付费重请求。

算法 1: GFPG：门控全信息策略梯度的增量自我改进

输入: 按批到达的训练题（$K = 4$ 批），验证集 $\mathcal{D}_{\text{val}}$，步长 η，每轮步数 S，正则系数 τ, λ，容差 $\epsilon = 0.03$

输出: 冻结的路由器 $\theta^{\star}$，验证集选出的最佳固定动作 $a^{\dagger}$

采集验证集每题三条动作的结果，得到 R^{val}

$\theta_0 \leftarrow (W = 0,\ b = (0, 0.5, 0))$；$\theta_{\text{inc}} \leftarrow \theta_0$；$\mathcal{H} \leftarrow \varnothing$ // 初始：总是 reason

for $k \leftarrow 1$ 到 K **do**

  对第 k 批每题执行 direct、reason、review（复用 reason 初稿），记录正确性与 token

  $\mathcal{H} \leftarrow \mathcal{H} \cup \{$第$k$ 批$\}$，按式 (1) 构造累计奖励矩阵 R

  $\theta' \leftarrow \theta_{\text{inc}}$ // 暖启动

  for $s \leftarrow 1$ 到 S **do**

    $\theta' \leftarrow \theta' + \eta \nabla_{\theta} J(\theta'; R)$ // 式 (4)，精确梯度

  if θ' 满足门控条件 (5) **then**

    $\theta_{\text{inc}} \leftarrow \theta'$ // 接纳

  else

    保留 θ_{inc}，存档 θ' // 拒绝并回退

$a^{\dagger} \leftarrow \arg\max_a U_{\text{val}}($固定$a)$

写入冻结文件（参数、版本号、$a^{\dagger}$、配置哈希、时间戳），之后才请求测试集

return $\theta^{\star} = \theta_{\text{inc}}$，$a^{\dagger}$

- **共享初稿**：review 复用同题 reason 的输出作为第一步，采集成本为每题 3 次；但部署成本始终按两次调用累计，不因缓存而少算。
- **冻结与一致性**：配置记录超参数、数据 SHA-256 与实现文件哈希；冻结文件先于任何测试请求写入；配置或实现变化时拒绝复用旧结果。
- **离线复核**：`scripts/replay_report.py` 不读密钥、不调用模型，重算评分、token 账、门控决策、测试指标与 bootstrap，并逐项比对。
- **密钥安全**：API 密钥只写入权限为 0600 的临时 header 文件，不出现在命令行参数、缓存或账本中。

4 AI 辅助设计过程

本项目在 AI 编程助手（大语言模型代理）辅助下完成。我们把 AI 的作用限定为“提出、推导、实现、检查”，把目标设定、约束与最终判断留给人，并要求 AI 的每一类产出都有可执行的核查手段。

4.1 人机分工

表 4 各环节的人机分工与留存证据

环节	AI 助手的工作	人的职责	仓库中的证据
问题筛选	归纳候选问题（过度推理、盲目复核、静态路由）并评估可测性与成本	确定研究问题与约 1000 次的总请求预算、指定模型接口	`research_plan.md` §1
方法推导	推导含熵正则的 softmax 策略梯度；提出以全信息反馈替代动作采样	审核推导，要求逐分量数值验证	`policy.py`、`test_policy.py`
实验设计	设计划分、门控规则、最佳固定基线、oracle 诊断与配对 bootstrap	确认“测试前冻结、不按测试结果调参”等规则	`research_plan.md` §4–§8
工程实现	编写 harness、预算账本、缓存、冻结、离线复核与单元测试	运行测试；在本地提供 API 凭据（不入库）	`harness_rsi/`、`tests/`
执行排障	遇到 HTTP 429 后加入全局节流与冷却；截断的空回答按答错计分并保留成本	确认修复发生在任何训练采集与测试之前	`config_history/`
结果解释	生成报告并强制与最佳固定策略比较；补充检查严格标注为探索性	接受负面结论，不挑选有利基线	`findings.md`、本报告

4.2 关键设计迭代

(1) 从“文本梯度”到数值梯度：TextGrad 式反馈无法做有限差分验证，也难以用课程中的收敛工具分析；因此改为对路由参数求解析梯度。

(2) 从采样梯度到全信息精确梯度：动作只有 3 条，且 review 可复用 reason 初稿，测全部动作每题只需 3 次请求；换来的是零采样方差的梯度（图 2b 量化了这一点）。

(3) 门控从“相对现任”扩展为“相对初始与现任的较高者”：防止多轮小幅下降累积成大幅退化。

(4) 传输层修复：服务端限流后加入全局节流与冷却；修复发生在训练采集与最终测试之前，旧配置哈希保留在 `config_history/`，题目与提示词未变。

(5) 结果审计：发现学习路由器未超过最佳固定策略后，没有替换主结论或更换基线；额外的 4000 步收敛检查被严格标注为探索性分析。

4.3 如何核查 AI 的产出

核查原则：AI 的每一类产出都对应一种可执行的检验

- **数学推导** → 中心差分逐分量比对解析梯度：48 个参数的最大绝对误差为 1.6×10^{-10}（图 2a）。
- **代码行为** → 36 项单元测试：预算并发下不可超支、缓存命中不计费、仅对 429/5xx 重试且每次计数、答案严格解析、报告生成格式等。
- **实验数值** → 离线复核脚本重算全部 304 题、912 次成功请求的 token 账与所有指标，并逐项比对。
- **结论表述** → 预先写定的解释规则（`research_plan.md` §8）：配对区间跨 0 时只能写“证据不足”。

5 实验设置

数据。 使用 GSM8K[5] 官方完整数据（train 7,473 行、test 1,319 行，逐行校验并记录 SHA-256）。训练与验证题只从官方 train 抽取，测试题只从官方 test 抽取；按规范化题面哈希去重，并剔除 train/test 间重复题。固定种子 42 抽样，不按难度或模型表现筛题：训练 128、验证 48、测试 128，共 304 题。

模型与调用。 通过 OpenAI 兼容的 `/v1/chat/completions` 接口调用 `deepseek-v4.1-flash`，温度 0，单次最大输出 2048 token。无失败时需要 $3 \times 304 = 912$ 次请求；本次运行的请求尝试上限为 980。

表 5 超参数（全部在实验前固定）

参数	取值	参数	取值
特征维数 / 参数量	15 / 48	成本权重 κ	0.05（每 1000 token）
熵系数 τ	0.01	L_2 系数 λ	0.03（偏置不正则）
学习率 η	0.2（全批量）	每轮步数 S	400
轮数 × 每批题数	4×32	初始策略	$W = 0$, $b = (0, 0.5, 0)$，即总是 reason
门控效用裕量	10^{-6}	门控准确率容差	0.03（相对初始与现任的较高者）
请求尝试上限	980（含失败重试）	部署规则	arg max，温度 0

基线与指标。 主要比较为“学习路由器 – 验证集选出的最佳固定路线”；辅助比较包括初始 reason、三条固定路线、均匀随机路由的期望指标，以及使用测试标签逐题选最优动作的 oracle（不可部署，仅作上界）。指标为准确率、平均 token、平均调用数、平均延迟与效用。

统计方法。 在同一批 128 道测试题上逐题计算差值，用 5000 次按题配对的 bootstrap 求 95% 百分位区间 [11]；每次重采样对两种策略使用同一组题目索引，保留同题相关性。解释规则在实验前写定：效用差区间下界大于 0 才称“取得正向证据”，跨 0 则称“证据不足”。

6 实验结果

6.1 方法正确性验证

图 2(a) 在真实训练特征与奖励上随机取参数点，对 48 个参数逐一做中心差分（$\varepsilon = 10^{-6}$）：解析梯度与数值梯度几乎完全重合，最大绝对误差 1.6×10^{-10}。

图 2(b) 量化了“全信息”带来的好处：在 v1 初始策略处，用已记录的奖励矩阵离线模拟 REINFORCE，并按真实 API 调用计费（温度 0 下重复采样同一动作命中缓存、不再计费；review 复用已采样的 reason 初稿）。每题 1 个采样时约需 164 次调用，梯度方向与精确梯度的平均余弦仅约 0.25；即使每题采样 16 次、调用数（约 383 次）已接近全信息采集的 384 次，平均余弦也只有约 0.76，且波动很大。GFPG 以 384 次调用得到方向完全准确（余弦为 1）、无方差的梯度。

为检验方法在“确有路由空间”时能否学到依赖上下文的决策，图 3 复现了单元测试中的合成任务：二维特征，左半平面动作 A 最优、右半平面动作 B 最优。精确梯度上升 350 步后，目标 J 单调上升，最优动作的平均概率升至 0.91，未见输入上的正确路由率为 98.0%。该实验只说明方法机制可行，不代表真实基准上的收益。

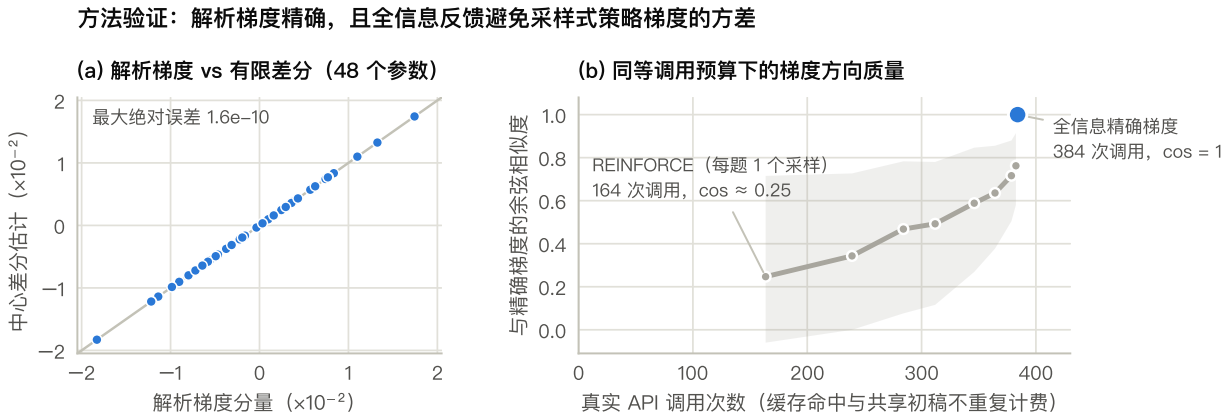


图 2 方法验证（离线，未新增 API 调用）。(a) 解析梯度与中心差分逐分量比较；(b) 同等真实调用预算下，REINFORCE 估计与精确梯度的余弦相似度（灰线为 400 次重复的均值，灰带为 10%–90% 分位）。

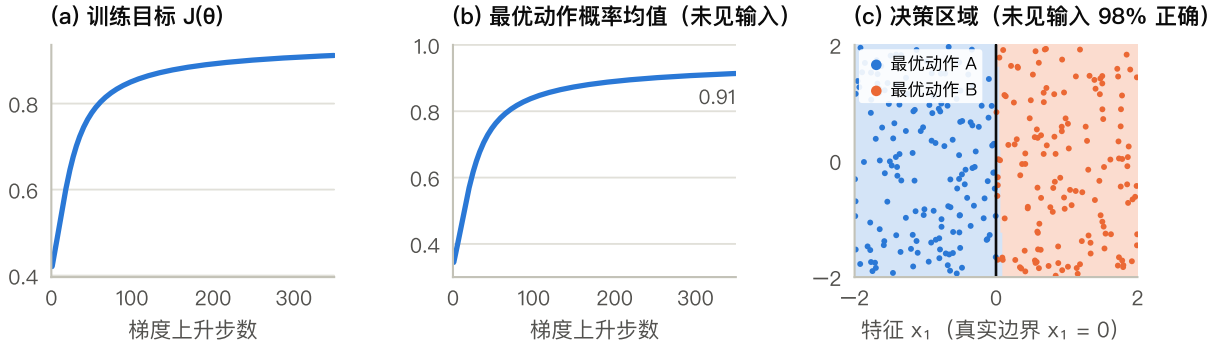


图 3 合成路由任务（与 `tests/test_policy.py` 相同的设定）。(c) 背景色为学到的决策区域，散点为未见输入按真实最优动作着色，黑线为真实边界。

6.2 独立测试集主结果

表 6 与图 4 给出冻结策略在 128 道独立测试题上的表现。

表 6 独立测试集结果（128 题；token 变化相对初始 reason；† oracle 使用测试标签，不可部署）

策略	答对	正确率	平均 token	token 变化 (%)	调用数	延迟 (s)	效用
梯度学习路由器（GFPG，冻结版本 3）	123/128	96.09%	322.0	−1.87	1.00	1.64	0.9448
验证集选出的最佳固定策略（direct）	124/128	96.88%	245.2	−25.28	1.00	1.10	0.9565
初始策略 = 固定 reason	123/128	96.09%	328.1	–	1.00	1.61	0.9445
固定 review（分步 + 复核）	123/128	96.09%	763.0	+132.52	2.00	3.26	0.9228
均匀随机（期望指标）	123.33/128	96.35%	445.4	+35.75	1.33	1.99	0.9413
逐题最优 Oracle†	124/128	96.88%	241.9	−26.29	1.00	1.09	0.9567

- **GFPG 路由器**：答对 123/128，与初始流程相同；平均 token 从 328.14 降至 322.00（−1.87%）。它对 7 题选择 direct、121 题选择 reason，从不选择 review。
- **最佳固定策略 direct**（由验证集选出）：答对 124/128，平均 token 仅 245.20（−25.28%），效用最

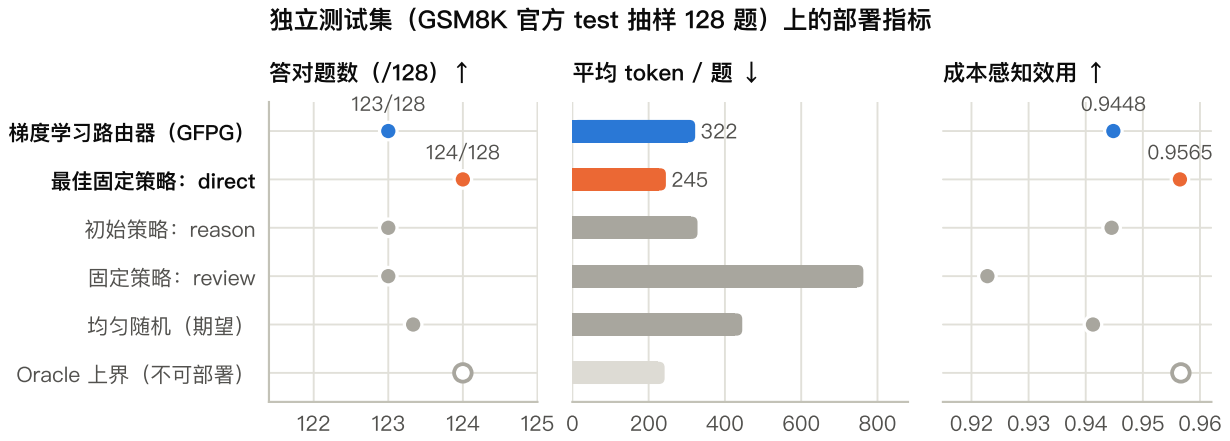


图 4 测试集部署指标。蓝色为 GFPG 冻结路由器，橙色为验证集选出的最佳固定策略，灰色为其他基线；空心点为不可部署的 oracle。效用 = 正确率 − 0.05×token/1000。答对题数轴未从 0 开始，以便看清一题之差。

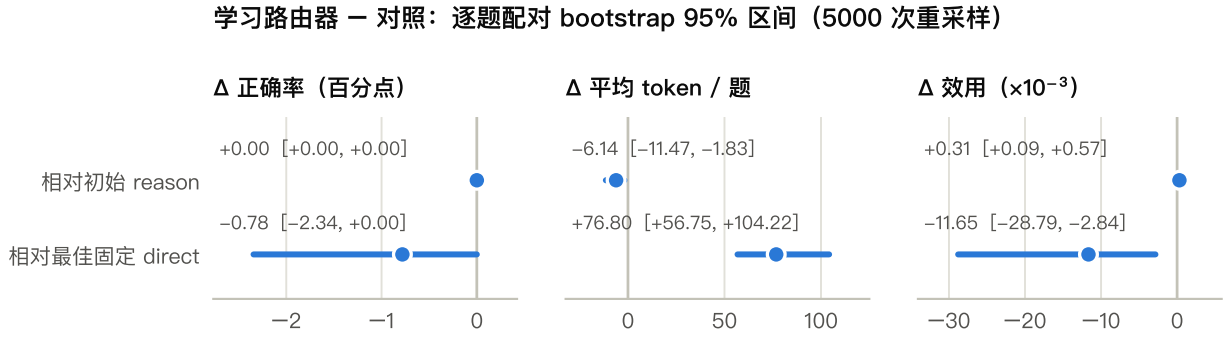


图 5 逐题配对 bootstrap 95% 区间。竖线为 0；区间不跨 0 表示差异在本测试分布与成本权重下可分辨。

高的可部署方案。

- 固定 **review**：准确率与 reason 相同，但 token 增加 +132.52%；复核纠正错误 0 次、改错正确答案 0 次。
- **Oracle**：答对 124/128，与固定 direct 相同，只比它再省 3.33 token/题（1.36%）。

6.3 配对统计检验

表 7 学习路由器 − 对照的逐题配对差值（点估计与 95% bootstrap 区间；准确率以百分点计）

对照	Δ 正确率（pp）		Δ token / 题		Δ 效用		效用结论
	点估计	95% 区间	点估计	95% 区间	点估计	95% 区间	
相对初始 reason	0.00	[0.00, 0.00]	−6.14	[−11.47, −1.83]	+0.00031	[+0.00009, +0.00057]	显著更优
相对最佳固定 direct	−0.78	[−2.34, 0.00]	+76.80	[+56.75, +104.22]	−0.01165	[−0.02879, −0.00284]	显著更差

结论一：相对初始 harness，GFPG 带来统计上可分辨的小幅改进

两者在 128 道题上的逐题正确性完全相同（准确率差恒为 0），而 token 差为 −6.14，95% 区间 [−11.47, −1.83]；效用差 +0.00031，区间 [+0.00009, +0.00057]，均不含 0。即：自我改进循环在不损失任何一道题的前提下，稳定地节省了少量 token。

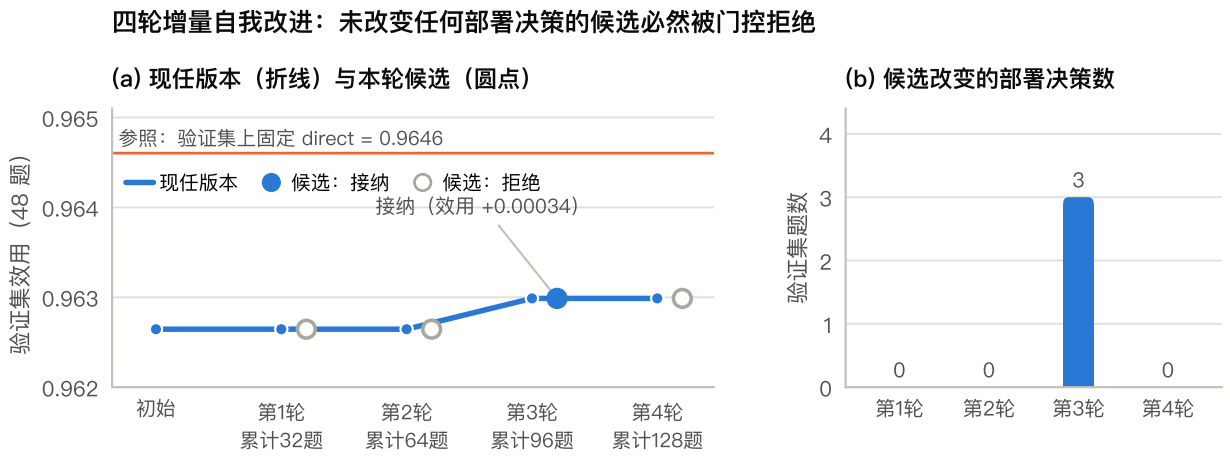


图 6 自我改进过程。(a) 验证集效用：折线为每轮结束后的现任版本，圆点为本轮候选；(b) 候选相对现任改变的验证集部署决策数（由已存档的候选参数重算）。

结论二：GFPG 显著劣于验证集选出的最佳固定策略

相对固定 direct，效用差为 −0.01165，95% 区间 [−0.02879, −0.00284] 完全位于 0 以下；每题多用 +76.80 token。准确率差 −0.78 个百分点的区间 [−2.34, 0.00] 含 0，因此不把 direct 多答对的 1 题宣称为显著的准确率优势。**在当前模型与基准下，实际部署更推荐固定 direct**；冻结的梯度路由器作为完整、可复现的方法实验保留。

6.4 自我改进过程

表 8 四轮自我改进记录（J 为训练代理目标；“决策变化”为候选与现任在验证集上 arg max 不同的题数）

轮次	累计训练题	J 起点	J 终点	现任验证效用	候选验证效用	决策变化	门控
1	32	0.95773	0.95924	0.96264	0.96264	0	拒绝
2	64	0.95693	0.95858	0.96264	0.96264	0	拒绝
3	96	0.95069	0.95491	0.96264	0.96299	3	接纳
4	128	0.94855	0.94923	0.96299	0.96299	0	拒绝

每轮梯度上升都提升了训练目标 J，但幅度很小。更关键的是图 6(b)：第 1、2、4 轮的候选在验证集上与现任做出完全相同的部署决策，验证效用因此毫无变化，只能被门控拒绝；只有第 3 轮候选把 3 道验证题从 reason 改为 direct，效用提升 0.00034 而被接纳，成为最终冻结的版本 3。我们把这种“改变了概率、却没有改变任何 arg max 决策”的更新称为**决策不可见的更新**，它是本实验中自我改进幅度受限的直接原因之一（§7.2）。

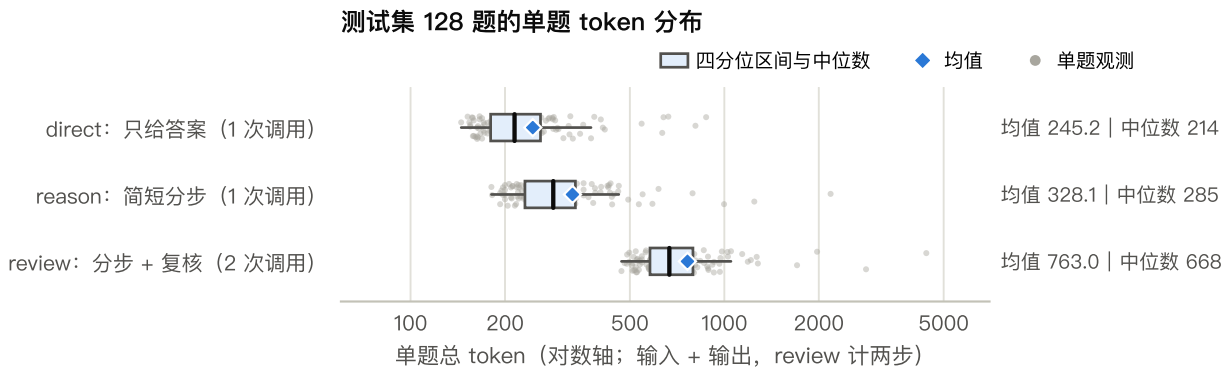


图 7 测试集单题 token 分布（对数轴）。review 的成本约为 reason 的 2.3 倍，却没有纠正任何错误。

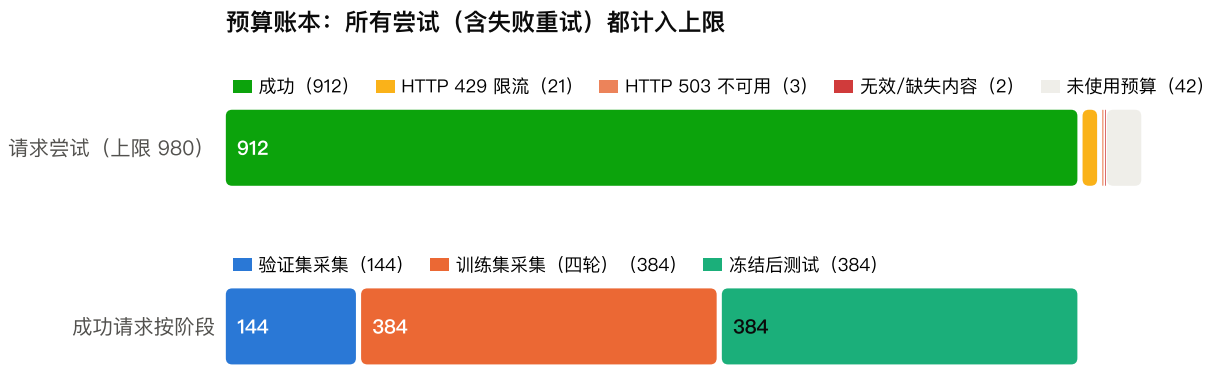


图 8 请求账本。上：全部尝试（含失败重试）相对上限 980；下：成功请求按阶段分解（与上方“成功”段同一比例尺）。

6.5 成本与预算

表 9 请求与 token 账本

项目	次数
验证集采集	144
训练集采集（四轮）	384
冻结后测试	384
失败：HTTP 429 限流	21
失败：HTTP 503 不可用	3
失败：无效/缺失内容	2
主实验尝试合计（上限 980）	938
另：早期连通性探测（独立账本）	1

主实验共尝试 938 次请求：成功 912 次、失败 26 次（以 HTTP 429 限流为主）；加上 1 次早期连通性探测，共 939 次，低于约 1000 次的授权上限。成功响应共记录 315,817 token（输入 156,018，输出 159,799）；失败请求若被供应商计费，其费用无法从日志还原。若未来题目分布与质量保持不变，按每题节省 6.14 token 计算，需要约 51,431 道后续题目才能摊销全部采集 token——这是有条件的估算，而非已获得的净收益。

7 分析与讨论

7.1 GFPG 在哪些方面是有效的

(1) **梯度精确、计算廉价**：解析梯度经逐分量有限差分验证；48 个参数的全批量更新在 CPU 上为毫秒级，无需 GPU。

(2) **全信息优于采样**：在相同调用预算下，采样式策略梯度的方向噪声很大（余弦约 0.25–0.76），而全信息梯度没有采样方差。

(3) **自我改进循环按设计工作**：只有改变了部署决策且通过门控的候选被接纳；冻结版本相对初始 harness 取得 CI 不含 0 的 token 节省，且逐题零准确率损失。

(4) **工程可信**：938 次请求未超预算；测试请求全部发生在冻结之后；全部指标可离线复核。

7.2 为什么没有超过最佳固定策略

(1) 路由空间几乎不存在。 oracle 与固定 direct 答对题数相同，只多省 1.36% 的 token。这意味着测试集上 direct 答错的 4 题，reason 与 review 也全部答错——三条路线在正确性上没有互补，而 direct 在 98.4% 的题上比 reason 更省 token。任何路由器的上限都只比“总是 direct”高出约 0.0002 的效用。

(2) 训练数据把学习引向 reason。 在 128 道训练题中，只有 1 题出现“direct 错而 reason 对”，反向情形为 0 题；但一题正确性的差别（$1/128 \approx 0.0078$）超过了 direct 平均节省 token 带来的效用（约 0.004）。于是在训练集上固定 reason 的效用（0.94398）反而高于固定 direct（0.94012），梯度自然把路由器推向 reason。在验证集上两者没有正确性差异（固定 direct 效用 0.96460，reason 0.96264），测试集上则是反向的 1 题。单题翻转这种稀有、大幅度的奖励差异，是小样本 harness 优化中最需要警惕的噪声来源。

(3) 步长预算不足导致“决策不可见的更新”。 每轮 400 步、学习率 0.2 的全批量梯度上升只让 logit 产生很小的变化，4 轮中有 3 轮候选没有改变任何验证集决策。仓库中另存的一次 4000 步收敛检查（只用前 64 道训练题与验证集）得到的路由在 48 道验证题上全部选择 direct，验证效用 0.9646，与固定 direct 相同。该检查是在看到早期验证结果后追加的，且冻结时间晚于第一次测试请求，因此只作为探索性证据，不替换原方案的结论（见 `artifacts/convergence_check/NOTE.md`）。

7.3 复核为何无效

固定 review 在测试集上纠正 0 题、改错 0 题，却让 token 增加 +132.52%。基础模型在 GSM8K 上的准确率已超过 96%，剩余错误多为三条路线同时答错的题，复核难以改变答案。此外 reason 与 review 各有 1 题因输出截断而未给出有效答案（direct 为 0 题），均按答错计分并保留其 token 成本。

7.4 对 RSI Harness 工程的启示

四条可迁移的经验

1. **永远与“验证集选出的最佳固定配置”比较**：只和初始配置比，会把“选对一个固定流程”的收益误认为自适应的功劳。
2. **先测路由空间，再加控制复杂度**：oracle 与最佳固定策略差距很小时，复杂路由器只会增加估计误差。
3. **让自我修改“决策可见”**：步长与停止准则应以部署决策是否改变为参照，而不仅是代理目标是否上升。
4. **预算账本与冻结协议是诚实评估的前提**：失败重试计费、测试前冻结、离线复核，使正负结果都可被他人核验。

8 局限性与后续工作

局限性。 仅一个模型、一个公开基准子集与一个训练种子；测试集 128 题，一题即 0.78 个百分点；每个（题目，动作）只有一次观测，温度 0 也不保证服务端完全确定；GSM8K 是公开数据，无法排除预训练污染；同一验证集被用于 4 次门控，存在自适应选择；bootstrap 区间只反映题目抽样的不确定性，不覆盖模型版本或服务端随机性；token 不等于货币成本。

后续工作。

(1) **自适应步长**：引入 Armijo 回溯线搜索、自然梯度（Fisher 预条件）或 Adam，并以“部署决策是否改变”作为每轮更新的检查点，避免决策不可见的更新。

(2) **稳健的奖励估计**：对稀有的正确性翻转做收缩或影响力限制，降低单题噪声对梯度方向的支配。

(3) **引入真正互补的动作**：例如调用计算器 / 代码执行、检索等；先在新的开发集上测量 oracle 空间，确有互补性再训练路由器。

(4) **确认性评估**：在从未用于探索的新测试集上，与验证集最佳固定策略和成本感知启发式做一次性比较；扩展到多模型、多种子与成本权重敏感性分析。

9 结论

本文在 AI 辅助下设计并实现了面向 LLM Harness 受限自我改进的梯度类方法 GFPG。它利用全信息反馈把策略梯度变为可解析、可验证、零采样方差的精确梯度，并通过带累计准确率守卫的验证门控与测试前冻结，构成一个预算受控、可审计的自我改进循环。在 938 次真实 API 请求的实验中，GFPG 相对初始 harness 取得了统计上可分辨、零准确率损失的小幅 token 节省；但它没有超过验证集选出的固定 direct 策略，oracle 诊断表明该基准上几乎不存在可供路由利用的空间。我们认为，这一“方法正确、收益有限、原因清楚”的完整结果，比只展示训练目标上升更能说明梯度类方法在真实 harness 自我改进中的价值与边界。

参考文献

[1] R. J. Williams. Simple statistical gradient-following algorithms for connectionist reinforcement learning. *Machine Learning*, 8(3–4):229–256, 1992.

[2] R. S. Sutton, D. McAllester, S. Singh, Y. Mansour. Policy gradient methods for reinforcement learning with function approximation. In *Advances in Neural Information Processing Systems 12*, 2000.

[3] J. Mei, C. Xiao, C. Szepesvári, D. Schuurmans. On the global convergence rates of softmax policy gradient methods. In *ICML*, 2020.

[4] J. Nocedal, S. J. Wright. *Numerical Optimization*, 2nd ed. Springer, 2006.

[5] K. Cobbe, V. Kosaraju, M. Bavarian, et al. Training verifiers to solve math word problems. arXiv:2110.14168, 2021.

[6] M. Yuksekgonul, F. Bianchi, J. Boen, S. Liu, Z. Huang, C. Guestrin, J. Zou. TextGrad: Automatic "differentiation"via text. arXiv:2406.07496, 2024.

[7] S. Hu, C. Lu, J. Clune. Automated design of agentic systems. arXiv:2408.08435, 2024.

[8] L. A. Agrawal, et al. GEPA: Reflective prompt evolution can outperform reinforcement learning. arXiv:2507.19457, 2025.

[9] J. Zhang, S. Hu, C. Lu, R. Lange, J. Clune. Darwin Gödel Machine: Open-ended evolution of self-improving agents. arXiv:2505.22954, 2025.

[10] Z. Shao, P. Wang, Q. Zhu, et al. DeepSeekMath: Pushing the limits of mathematical reasoning in open language models. arXiv:2402.03300, 2024.

[11] B. Efron, R. J. Tibshirani. *An Introduction to the Bootstrap*. Chapman & Hall/CRC, 1993.

附录 A 复现指南

需要 Python 3.10+、NumPy 与系统 `curl`。以下命令在仓库根目录执行（Windows PowerShell 同样适用，环境变量写法见 README）。

```
# 1. Install the only runtime dependency and run the unit tests
python -m pip install -r requirements.txt
python -m unittest discover -s tests -v

# 2. Re-verify every recorded number offline (no API key, no model call)
python scripts/replay_report.py --run artifacts/gsm8k_flash_v1

# 3. Re-draw the report figures and tables (needs matplotlib)
python -m pip install -r requirements-report.txt
python scripts/make_figures.py

# 4. Re-build this PDF (XeLaTeX + ctex), then copy it to the repository root
cd report && latexmk -xelatex main.tex && cp main.pdf ../REPORT.pdf

# 5. Optional: rerun the real-API experiment (needs your own key; costs requests)
export HARNESS_BASE_URL=https://your-provider.example/v1
export HARNESS_MODEL=your-model HARNESS_API_KEY=...
python scripts/download_data.py
python -m harness_rsi.experiment --output artifacts/my_run --max-requests 980 --workers 4
```

离线复核会校验实现文件哈希、数据划分、逐题评分、逐请求 token 账、冻结策略、每轮门控、测试指标、配对 bootstrap 与预测导出，全部通过时输出 `verified_offline`。

附录 B 仓库结构

路径	内容
REPORT.pdf	本报告（课程提交用 PDF）
README.md	项目说明、关键结果与快速开始
harness_rsi/	核心实现：client（预算与缓存）、tasks、strategies、policy（梯度）、experiment、evaluation、report
scripts/	数据下载、离线复核、作图、冻结策略推理、探索性收敛检查
tests/	单元测试（梯度、预算、缓存、评分、门控、报告生成）
artifacts/gsm8k_flash_v1/	真实实验：配置、逐题观测、请求账本、各轮候选、冻结策略、测评报告
artifacts/convergence_check/	探索性 4000 步收敛检查（如实标注，不替换主结论）
docs/	研究计划、结果讨论、来源核验记录
report/	本报告的 LaTeX 源码、图表与自动生成的数值表

附录 C 自动化测试清单

表 10 单元测试覆盖（python -m unittest discover -s tests）

文件	数量	覆盖内容
test_policy.py	6	解析梯度 vs 有限差分；合成任务上学会上下文路由；标准化冻结与序列化；数值稳定的 softmax；特征不依赖答案；拒绝不完整奖励矩阵
test_client.py	13	缓存命中不计费且预算跨重启保留；并发下预算不超支；相同请求只发一次；缺失 / 零 usage 视为失败；仅对 429/5xx 重试且计数；截断空回答保留成本；全局节流与 429 冷却；密钥不进命令行
test_evaluation.py	5	指标与效用公式；随机策略的期望指标；相同策略的配对区间恰为 0；差值符号与种子可复现；非法输入拒绝
test_tasks.py	6	数值解析与精确比较；不从推理过程猜答案；最后一个显式答案生效；官方划分去重与确定性；合成题；路线提示不含标签
test_experiment.py	1	测试请求必须晚于冻结；review 部署成本计两步
test_report.py	5	测评报告生成：关键数值与两组对照；效用结论随配对区间变化；统一 LF 换行；SVG 结构合法；缺失字段降级与表格转义