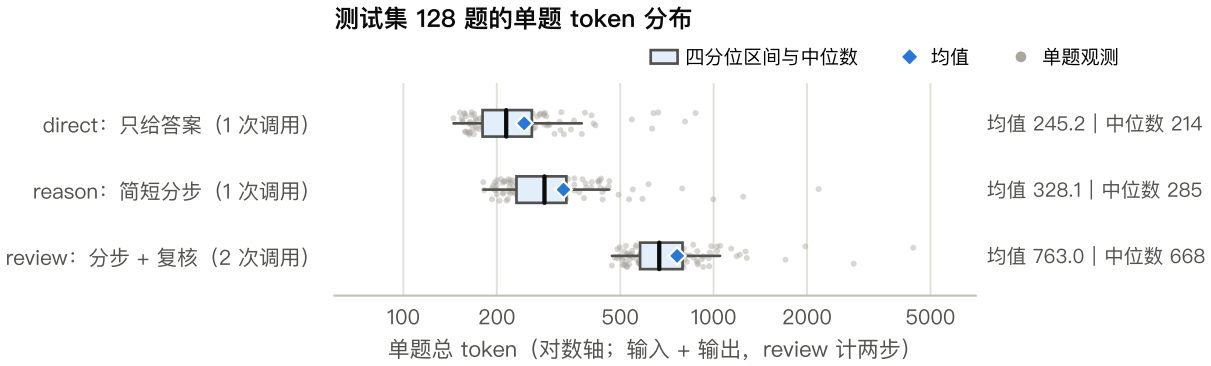
测试集 128 题的单题 token 分布
四分位区间与中位数
均值
单题观测
direct：只给答案（1 次调用）
reason：简短分步（1 次调用）
review：分步 + 复核（2 次调用）
均值 245.2 | 中位数 214
均值 328.1 | 中位数 285
均值 763.0 | 中位数 668
100
200
500
1000
2000
5000
单题总 token（对数轴；输入 + 输出，review 计两步）